Python爬虫实战-爬取TIOBE TOP20语言排行榜

URL: index | TIOBE - The Software Quality Company

IDE: PyCharm Professional

要爬取的是排名前20的语言榜单,并将其存成文本文件和生成词云

Mar 2022	Mar 2021	Change	Progra	mming Language	Ratings	Change
1	3	^		Python	14.26%	+3.95%
2	1	~	9	С	13.06%	-2.27%
3	2	•	4	Java	11.19%	+0.74%
4	4		8	C++	8.66%	+2.14%
5	5		©	C#	5.92%	+0.95%
6	6		VB	Visual Basic	5.77%	+0.91%
7	7		JS	JavaScript	2.09%	-0.03%
8	8		php	PHP	1.92%	-0.15%
9	9		ASM	Assembly language	1.90%	-0.07%

这个榜单包括6列,分别是2022年3月的排名(Mar 2022)、2021年3月的排名(Mar 2021)、增减、程序语言(Programming Language)、占比(Ratings)、变化率(Change)

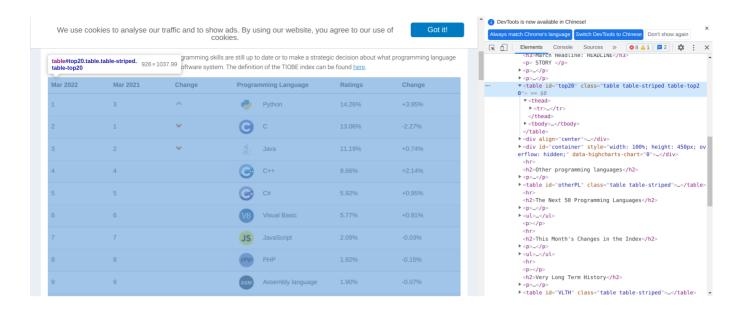
前置准备

导入要用的库

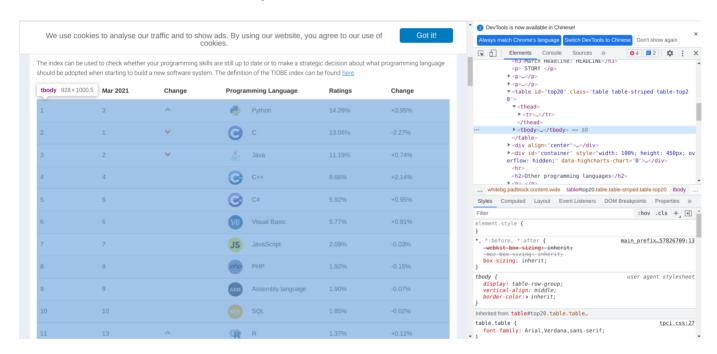
```
import requests
from bs4 import BeautifulSoup
import re
import wordcloud
```

requests是用来发起https请求,并获取结果的。BeautifulSoup用于解析网页html代码,re用于正则匹配,wordcloud用于生成词云。

检查网页源代码,可以发现整个榜单放id为top20的table标签下



榜单的主体在这个table标签的tbody标签下



而每一行都被划分在tbody一个tr标签下



知道这些就足够了,下面编写代码

获取数据

```
url = "https://www.tiobe.com/tiobe-index/"
res = requests.get(url)
soup = BeautifulSoup(res.text,"html.parser")
table = soup.find("table", id="top20").find("tbody").find_all("tr")
```

上述代码获取了网页html源码并解析,返回一个soup对象,使用find和find all函数根据标签查 找,获取tr标签下数据组成的列表

接下来将其打印出来看看

打印出了每一个tr标签下的内容,要获取的数据就在其中

```
for item in table:
    print(item.text)
```

那直接取出文本

/usr/bin/python3.7 /home/hwx/PycharmProjects/work/main.py 13Python14.26%+3.95% 21C13.06%-2.27% 32Java11.19%+0.74% 44C++8.66%+2.14% 55C#5.92%+0.95% 66Visual Basic5.77%+0.91% 77JavaScript2.09%-0.03% 88PHP1.92%-0.15% 99Assembly language1.90%-0.07% 1010SQL1.85%-0.02% 1113R1.37%+0.12% 1214Delphi/Object Pascal1.12%-0.07% 1311Go0.98%-0.33% 1419Swift0.90%-0.05% 1518MATLAB0.80%-0.23% 1616Ruby0.66%-0.52% 1712Classic Visual Basic0.60%-0.66% 18200bjective-C0.59%-0.31% 1917Perl0.57%-0.58% 2038Lua0.56%+0.23%

现在拿到的数据就很间接了,程序将单个标签下所有的文本都连接到了一起

现在已经获取到了数据,接下来要做的是数据处理

Process finished with exit code 0

数据处理

现在获取的仅仅是文本,接下来要对其进行分割

这时派上用场的是正则表达式

这里使用re模块中的search函数

re.search(pattern, string, flags=0) # 扫描整个字符串并返回第一个成功的匹配。

参数	描述						
pattern	匹配的正则表达式						
string	要匹配的字符串						
flags	标志位,用于控制正则表达式的匹配方式,如:是否区分大小写,多行匹配等等						

不难发现,在上面爬到的文本中,每一行的第一个数字就是语言的当前排名(1,2,3...),因此这是固定的,后面紧跟的数字是去年排名,再跟着的若干单词是语言的名字,随后两个百分数就是占比和变化率。

那么每一次循环中,都是对一行的文本中数据的提取。

首先剔除每一行的第一个数字即当前排名,那么到字母之前剩下的数字就是去年排名,可以轻易的写出正则表达式"[0-9]+",来匹配第一个出现的纯数字。

随后就是语言名字了,直接匹配第一个非数字字符串即可,即"\D+"。

接下来要匹配占比,显然这个百分数后面都会跟着一个正号或负号,因此表达式可以写成

"(\d+.([0-9]?)%+)|(\d+.([0-9]?)%-)",最后剩下的是变化率,这个百分数之前都有正负号,所以可以直接写出"-(.?)%|+(.?)%"。最后得到的结果用.group()函数取出即可

每一行提取出的数据放到一个元组里

```
current_rand = 1
for item in table:
    if current_rand < 10:
        target = item.text[1:]
    else:
        target = item.text[2:]
    previous_rand = re.search(r"[0-9]+", target).group()
    language = re.search(r"(\D)+", target).group()
    ratings = re.search(r"(\d+\.([0-9]*?)%\+)|(\d+\.([0-9]*?)%-)",
target).group()[:-1]
    change = re.search(r"-(.*?)%|\+(.*?)%", target).group()
    current_rand = current_rand + 1</pre>
```

再循环中将结果打印

```
/usr/bin/python3.7 /home/hwx/PycharmProjects/work/main.py
('1', '3', 'Python', '14.26%', '+3.95%')
('2', '1', 'C', '13.06%', '-2.27%')
('3', '2', 'Java', '11.19%', '+0.74%')
('4', '4', 'C++', '8.66%', '++8.66%')
('5', '5', 'C#', '5.92%', '+0.95%')
('6', '6', 'Visual Basic', '5.77%', '+0.91%')
('7', '7', 'JavaScript', '2.09%', '-0.03%')
('8', '8', 'PHP', '1.92%', '-0.15%')
('9', '9', 'Assembly language', '1.90%', '-0.07%')
('10', '10', 'SQL', '1.85%', '-0.02%')
('11', '13', 'R', '1.37%', '+0.12%')
('12', '14', 'Delphi/Object Pascal', '1.12%', '-0.07%')
('13', '11', 'Go', '0.98%', '-0.33%')
('14', '19', 'Swift', '0.90%', '-0.05%')
('15', '18', 'MATLAB', '0.80%', '-0.23%')
('16', '16', 'Ruby', '0.66%', '-0.52%')
('17', '12', 'Classic Visual Basic', '0.60%', '-0.66%')
('18', '20', 'Objective-C', '0.59%', '-C0.59%')
('19', '17', 'Perl', '0.57%', '-0.58%')
('20', '38', 'Lua', '0.56%', '+0.23%')
```

因为最后的结果要保存,所以要定义一个列表,将元组放到列表中

考虑到要生成词云,所以同样要定义一个字典,与程序语言名称为key,以占比为值,这里要把百分比的%去掉,然后转化为浮点数

```
words = {}
result = []
current rand = 1
for item in table:
    if current rand < 10:</pre>
        target = item.text[1:]
    else:
        target = item.text[2:]
    previous_rand = re.search(r"[0-9]+", target).group()
    language = re.search(r"(\D)+", target).group()
    ratings = re.search(r''(\d+\.([0-9]*?)\%\+)|(\d+\.([0-9]*?)\%-)'',
target).group()[:-1]
    change = re.search(r"-(.*?)%|\+(.*?)%", target).group()
    result.append((str(current_rand), previous_rand, language, ratings,
change))
    words[language] = float(ratings.strip("%"))
    current_rand = current_rand + 1
```

得到列表后,保存文本文件

上述代码中使用了格式化字符串,利用了format函数,利用open函数打开一个文件,指定标志为"w+",使用write函数向其中写入数据,使用close函数最后关闭文件

如下是生成词云的代码,width和height指定长宽,background color制定背景色

```
w = wordcloud.WordCloud(width=1000, height=700, background_color="white")
w.generate_from_frequencies(words)
w.to_file("result.png")
```

generate from frequencies接收一个字典

to file生成最后的图片文件

完整代码如下

```
import requests
from bs4 import BeautifulSoup
import re
import wordcloud
url = "https://www.tiobe.com/tiobe-index/"
res = requests.get(url)
soup = BeautifulSoup(res.text,"html.parser")
table = soup.find("table", id="top20").find("tbody").find_all("tr")
words = \{\}
result = []
current rand = 1
for item in table:
    if current_rand < 10:</pre>
        target = item.text[1:]
   else:
        target = item.text[2:]
   previous_rand = re.search(r"[0-9]+", target).group()
    language = re.search(r"(\D)+", target).group()
    ratings = re.search(r''(\d+\.([0-9]*?)\%\+)|(\d+\.([0-9]*?)\%-)'',
target).group()[:-1]
    change = re.search(r"-(.*?)%|+(.*?)%", target).group()
    result.append((str(current_rand), previous_rand, language, ratings,
change))
   words[language] = float(ratings.strip("%"))
    current_rand = current_rand + 1
f = open("result.txt", "w+")
f.write("Mar 2022 Mar 2021 Programming Language
                                                             Ratings
Change\n")
for item in result:
    line = \{(<10)\t{(<20)\t{(<10)}}.format(item[0], item[1],
item[2], item[3], item[4])
    f.write(line + "\n")
f.close()
w = wordcloud.WordCloud(width=1000, height=700, background color="white")
w.generate_from_frequencies(words)
w.to file("result.png")
```

最后生成了如下的文本文件

1	Mar 2022	Mar 2021	Programming Language	Ratings	Change
2	1	3	Python	14.26%	+3.95%
3	2	1	C	13.06%	-2.27%
4	3	2	Java	11.19%	+0.74%
5	4	4	C++	8.66%	++8.66%
6	5	5	C#	5.92%	+0.95%
7	6	6	Visual Basic	5.77%	+0.91%
8	7	7	JavaScript	2.09%	-0.03%
9	8	8	PHP	1.92%	-0.15%
10	9	9	Assembly language	1.90%	-0.07%
11	10	10	SQL	1.85%	-0.02%
12	11	13	R	1.37%	+0.12%
13	12	14	Delphi/Object Pascal	1.12%	-0.07%
14	13	11	Go	0.98%	-0.33%
15	14	19	Swift	0.90%	-0.05%
16	15	18	MATLAB	0.80%	-0.23%
17	16	16	Ruby	0.66%	-0.52%
18	17	12	Classic Visual Basic	0.60%	-0.66%
19	18	20	Objective-C	0.59%	-C0.59%
20	19	17	Perl	0.57%	-0.58%
21	20	38	Lua	0.56%	+0.23%

以及词云图片

